

BIODATA

Relatório Técnico — Engenharia de Dados aplicada à Biodiversidade

Criador: Homero Flávio

Área: Engenharia e Análise de Dados **Ano:** 2026

1. Visão geral

O Biodata é uma solução de Engenharia de Dados voltada à integração, tratamento, armazenamento e visualização de dados de biodiversidade. O projeto integra GBIF, IUCN, ICMBio e PANs e utiliza Python, Pandas, PostgreSQL, Apache Airflow, Docker e Plotly Dash.

2. Objetivos

Construir uma pipeline ETL real, trabalhar com APIs e dados heterogêneos, aplicar limpeza e transformação, organizar uma camada analítica relacional, automatizar o fluxo com Airflow e disponibilizar os dados em um dashboard.

3. Fontes

GBIF fornece ocorrências e localização; IUCN fornece avaliações e categorias de conservação; ICMBio fornece informações de conservação de espécies no Brasil; PAN representa planos de ação voltados à conservação.

4. Arquitetura

Fontes externas → Extract/Bronze → Transform/Prata → Load/Ouro → PostgreSQL/Neon → SQL/Queries → Dash. O Airflow atua como orquestrador e o Docker fornece o ambiente de execução.

5. ETL

A extração é dividida por fonte. A transformação realiza limpeza, padronização, conversão de tipos, tratamento de ausências e organização das estruturas analíticas. A carga envia os dados transformados para PostgreSQL.

6. Banco de dados

O banco possui dimensões e fatos como `dim_especie`, `dim_local`, `dim_pan`, `dim_categoria_risco`, `fato_avaliacao_icmbio`, `fato_avaliacao_iucn` e `fato_ocorrencia_gbif`, além de tabelas de relacionamento PAN e `especie_destaque`.

7. Dashboard

O Plotly Dash apresenta páginas de contexto, conservação, Brasil, distribuição, evolução, PANs e espécies em destaque, alimentadas por consultas SQL ao banco.

8. Airflow e Docker

A DAG `biodata_etl` organiza tarefas de extração, transformação, carga e carregamento das espécies em destaque. O Docker Compose organiza Airflow, Scheduler, DAG Processor e banco de metadados.

9. Migração para a nuvem

O PostgreSQL utilizado inicialmente no ambiente local foi migrado para o Neon. A escolha preservou PostgreSQL como banco principal e permitiu que o dashboard fosse desacoplado da máquina local. O Dash está sendo preparado para publicação no Render.

10. Desafios

Foram enfrentadas diferenças entre fontes, valores ausentes, nomenclaturas, tipos, datas, coordenadas e limitações de APIs. A manipulação temporal foi simplificada com ano_observacao. Também houve desafios relacionados ao ambiente Oracle, levando à consolidação da camada analítica em PostgreSQL.

11. Segurança

Credenciais de banco e chaves de API são mantidas em variáveis de ambiente. O arquivo .env não deve ser versionado.

12. Stack

Python, Pandas, SQL, PostgreSQL, Neon, Apache Airflow, Docker, Docker Compose, Plotly Dash, Plotly, Psycopg2 e Git/GitHub.

13. Estado atual

O banco já está no Neon e o dashboard foi validado localmente utilizando a conexão em nuvem. A próxima etapa é o deploy do Dash no Render. O Airflow permanece no ambiente de desenvolvimento atual.

14. Melhorias futuras

Hospedagem remota do Airflow, atualização automática, testes, monitoramento, validações de qualidade, alertas, observabilidade, novas fontes e eventual evolução para Data Lake/Lakehouse quando houver justificativa técnica.

15. Conclusão

O Biodata consolida conhecimentos de Engenharia de Dados em um fluxo completo, desde APIs externas e dados brutos até transformação, modelagem, orquestração, banco em nuvem e visualização analítica.

Arquitetura resumida

Camada	Tecnologia	Função
Fontes	GBIF / IUCN / ICMBio / PAN	Dados externos
Extract / Bronze	Python	Coleta e dados brutos
Transform / Prata	Python + Pandas	Limpeza e padronização
Load / Ouro	PostgreSQL	Armazenamento analítico
Orquestração	Apache Airflow	Dependências e execução
Ambiente	Docker / Compose	Execução reproduzível
Visualização	Dash + Plotly	Dashboard
Cloud	Neon	PostgreSQL em nuvem
Deploy	Render	Hospedagem do Dash